

企业知识库问答系统介绍

企业知识库问答系统是一套基于 RAG（检索增强生成）技术的内部知识问答平台。它允许员工上传各类文档，并通过自然语言提问，快速获取带出处引用的答案。

系统架构

系统采用 PostgreSQL 存储业务数据与会话数据，并使用 pgvector 扩展在同一个数据库内存储向量数据。后端使用 FastAPI 提供 REST API，并通过 SSE 协议流式返回大模型生成的内容。文档解析支持 txt、markdown、pdf 和 docx 四种格式。

文档入库流程

用户上传文档后，系统按文件类型解析出纯文本，然后按 chunk_size 和 overlap 参数进行分块。每个分块调用 Embedding 模型生成向量，写入 chunks 表的 embedding 列，并更新文档状态为 ready。如果处理失败，文档状态会变为 failed，用户可以手动触发重试。

问答流程

用户提问时，系统先将问题向量化，在知识库中做余弦相似度检索，取 Top-K 个最相关的分块。系统会把检索到的分块作为上下文拼装 Prompt，调用大模型生成回答，并通过 SSE 流式返回。回答下方会展示引用来源，包括文档名和具体片段，保证答案可追溯。

分块策略

默认 chunk_size 为 500 字符，overlap 为 100 字符。分块时优先在句子边界或段落边界处切分，避免把一句话从中间硬切成两段，从而保留语义完整性。